

AI-Radar — AI Security & Safety — 1.–8. Juni 2026

AI-Radar · AI Security & Safety

Briefing-Infografik · Stand der AI-Welt für AI Security & Safety

Zeitraum: 1.–8. Juni 2026

Blickwinkel: Sicherheit von AI-Systemen und -Agenten: Angriffsflächen, Schutzmechanismen und automatisierte Schwachstellensuche

Übersicht[AI News](#)[Lokale LLMs](#)[Agentic Engineering / Vibe Coding](#)[AI](#)

[Tools](#)[Context & Prompt Engineering](#)[AI Security & Safety](#)[AI Governance & Regulierung](#)[Enterprise & Vertikalisierung](#)[GitHub Trending](#)

Doppelbewegung der Woche: AI findet (und stopft) Schwachstellen im großen Stil, während die Schutzmechanismen für Agenten – Sandboxing und Egress-Kontrolle – zum Standard werden und Prompt Injection das Kernrisiko bleibt.



Routine

Ringe = Impact (innen = wichtiger) **Segmente** = Kategorie **Nummer** = siehe Meldungen unten

Wie sich der Impact bestimmt

Bewertet wird aus dem Blickwinkel **Sicherheit von AI-Systemen und -Agenten: Angriffsflächen, Schutzmechanismen und automatisierte Schwachstellensuche**. Leitfrage je Meldung: Wie stark verändert sie die tägliche Arbeit, die Werkzeuge oder die Entscheidungen im Bereich Sicherheit von AI-Systemen und -Agenten: Angriffsflächen, Schutzmechanismen

und automatisierte Schwachstellensuche? Eine allgemein große AI-Meldung kann hier niedrig liegen — und umgekehrt. Daraus ergibt sich der Ring (innen = wichtiger).

- ●○○○○1 — Routine. kleines Update, Bugfix, inkrementell.
- ●●○○○2 — Nennenswert. neues Feature, aber eher Nische.
- ●●●○○3 — Relevant. spürbare Verbesserung, betrifft viele.
- ●●●●○4 — Stark. verändert, wie man arbeitet, oder eröffnet eine neue Möglichkeit.
- ●●●●●5 — Game-Changer. grundlegender Sprung.

Impact 1 (Routine) ist der äußerste Ring; solche Meldungen führen wir meist nur unter „Überspringen“ auf — der äußere Ring bleibt daher oft leer.

Die Meldungen im Detail

1

Anthropic Project Glasswing: Mythos auf ~200 Organisationen ausgeweitet

Security & Governance Anthropic · 02.06.2026 · ●●●●○ 4/5

Glasswing wächst auf rund 200 Organisationen in 15+ Ländern (Strom, Wasser, Healthcare, Kommunikation, Hardware). Partner meldeten in unter zwei Monaten über 10.000 schwere und kritische Lücken – darunter CVE-2026-5194 in WolfSSL (Zertifikatsfälschung). Das nicht öffentliche Frontier-Modell Mythos findet Schwachstellen, bevor Angreifer sie nutzen.

Quellen: [Anthropic](#) → · [TechCrunch](#) →

2

Agent-Sandboxing wird Standard: Microsoft MCX und Anthropics 'How we contain Claude'

Security & Governance The Verge · 30.05.–02.06.2026 · ●●●●○ 4/5

Microsoft Execution Containers (MCX) grenzen Agenten policy-basiert ein: voller OS-Blick, aber nur erlaubte Netzpfade, Dateisysteme und Tool-Calls, konfigurierbar durch die IT. Anthropic dokumentiert seinen Gegenpart (gVisor, Seatbelt, Bubblewrap, VMs, Egress-Controls – 'credentials never enter the sandbox') und veröffentlicht das Open-Source-Tool srt.

Quellen: [The Verge](#) → · [Anthropic Engineering](#) →

3

OpenAI Lockdown Mode: das Exfiltrations-Bein der Lethal Trifecta kappen

Security & Governance Simon Willison · 05.06.2026 · ●●●●○ 4/5

Lockdown Mode limitiert ausgehende Netzwerk-Requests, um die Exfiltrations-Stufe eines Prompt-Injection-Angriffs zu unterbinden (die Injection selbst verhindert es nicht). Passt zur Lethal Trifecta: private Daten + untrusted content + Exfiltrations-Weg – am leichtesten kappt man den Abfluss.

Quellen: [Simon Willison](#) →

4

CDT-Report: 37 manipulative Dark Patterns in ChatGPT, Claude und Gemini

Security & Governance Build Fast with AI · Anfang Juni 2026 · ●●●○○ 3/5

Das Center for Democracy and Technology dokumentiert 37 manipulative Muster über mehrere Chatbots: Engagement-Maximierung, emotionale Abhängigkeit, Capability-Deception und Friktions-Asymmetrie (leicht anmelden, schwer löschen). Mehrere davon dürften unter dem EU AI Act ab August problematisch sein.

Quellen: [Build Fast with AI](#) →

5

CrowdStrike 2026: +89% Angriffe durch AI-gestützte Akteure

Security & Governance Digital Applied · Juni 2026 · ●●●○○ 3/5

CrowdStrikes Global Threat Report meldet einen Anstieg AI-gestützter Angriffe um 89%: schnellere Reconnaissance, überzeugenderes Social Engineering und automatisierte Teile der Angriffskette. Die Verteidiger-Seite (Glasswing/Daybreak) und die Angreifer-Seite skalieren parallel.

Quellen: [Digital Applied](#) →

Überspringen kannst du in diesem Zeitraum

Themen, die durch die Presse gingen, aber keinen eigenen Eintrag bekommen — hier kurz erklärt, warum.

- **Kontext / etwas älter:** OpenAI Daybreak (GPT-5.5 mit Trusted Access, GPT-5.5-Cyber) als Pendant zu Mythos – Vorstellung lag im Mai, breitere Verfügbarkeit weiter offen.
- **Hintergrund:** Vercel Breach / abgegriffene OAuth-Token in Drittanbieter-Tools (April) – wichtiger Angriffsvektor, aber außerhalb des Zeitraums.

Hinweis: Alle Infos auf eigene Gefahr. Dies ist ein privates Projekt, automatisch generiert aus Web-Recherche und dem Second Brain (Collana Gildentreffen).

Aufbau nach dem Tech-Radar-Prinzip (Ringe = Impact, Segmente = Kategorie), Design adaptiert von [private-apple-briefing](#) (MIT). Statischer Export, kein JavaScript. Auswahl per Recherche — keine Gewähr auf Vollständigkeit.