

AI-Radar — Lokale LLMs — 1.–8. Juni 2026

AI-Radar · Lokale LLMs

Briefing-Infografik · Stand der AI-Welt für Lokale LLMs

Zeitraum: 1.–8. Juni 2026

Blickwinkel: On-Device- und Open-Weight-Modelle: lokal lauffähig, datenschutz- und kostenrelevant

Übersicht[AI News](#)[Lokale LLMs](#)[Agentic Engineering / Vibe Coding](#)[AI](#)

[Tools](#)[Context & Prompt Engineering](#)[AI Security & Safety](#)[AI Governance & Regulierung](#)[Enterprise & Vertikalisierung](#)[GitHub Trending](#)

Open-Weight schließt weiter auf: MiniMax M3 bringt Frontier-Coding mit 1M-Kontext als offenes Modell, Gemma 4 12B macht agentic-fähige Agents auf dem Laptop salonfähig, und VS Code unterstützt lokale Modelle jetzt komplett offline.



Routine

Ringe = Impact (innen = wichtiger) **Segmente** = Kategorie **Nummer** = siehe Meldungen unten

Wie sich der Impact bestimmt

Bewertet wird aus dem Blickwinkel **On-Device- und Open-Weight-Modelle: lokal lauffähig, datenschutz- und kostenrelevant**. Leitfrage je Meldung: Wie stark verändert sie die tägliche Arbeit, die Werkzeuge oder die Entscheidungen im Bereich On-Device- und Open-Weight-Modelle: lokal

lauffähig, datenschutz- und kostenrelevant? Eine allgemein große AI-Meldung kann hier niedrig liegen — und umgekehrt. Daraus ergibt sich der Ring (innen = wichtiger).

- ●○○○○1 — Routine. kleines Update, Bugfix, inkrementell.
- ●●○○○2 — Nennenswert. neues Feature, aber eher Nische.
- ●●●○○3 — Relevant. spürbare Verbesserung, betrifft viele.
- ●●●●○4 — Stark. verändert, wie man arbeitet, oder eröffnet eine neue Möglichkeit.
- ●●●●●5 — Game-Changer. grundlegender Sprung.

Impact 1 (Routine) ist der äußerste Ring; solche Meldungen führen wir meist nur unter „Überspringen“ auf — der äußere Ring bleibt daher oft leer.

Die Meldungen im Detail

1

MiniMax M3: Open-Weight-Frontier mit 1M-Kontext und MSA-Architektur

Open Weight / Lokalthe-decoder · 01.06.2026 · ●●●●○ 4/5

MiniMax M3 kombiniert als erstes Open-Weight-Modell Frontier-Coding, 1-Mio.-Token-Kontext und native Multimodalität. SWE-Bench Pro 59,0% (vor GPT-5.5 und Gemini 3.1 Pro, aber unter Opus 4.8 mit 69,2%). Vorsicht: Benchmarks sind herstellergemessen, die Gewichte und der Tech-Report folgen erst auf Hugging Face/GitHub.

Quellen: [the-decoder](#) → · [MarkTechPost](#) →

2

Google Gemma 4 12B: tool-enabled, läuft lokal via Ollama

Open Weight / LokalComputerworld · 03.06.2026 · ●●●●○ 4/5

Gemma 4 (12B-Variante) ist agentic-fähig (Tool Calling) und läuft lokal via Ollama auf einem normalen Laptop. Starkes Argument für lokale Agenten in Offline- und Datenschutz-Szenarien – genau die Use Cases aus ISO-kritischen Kundenprojekten.

Quellen: [Computerworld](#) →

3

VS Code unterstützt lokale Modelle vollständig offline

Tools & IDEs [A Guide to Cloud · Build 2026](#) · ●●●○○ 3/5

Auf der Build 2026 angekündigt: VS Code kann KI-Coding-Assistenz mit lokalen Modellen auch ohne Copilot-Subscription und ohne Internet nutzen – wichtig für abgeschottete Unternehmensumgebungen.

Quellen: [A Guide to Cloud](#) →

4

Microsoft MAI-Familie: effiziente MoE-Modelle als OpenAI-Alternative

Modelle [Simon Willison · 02.06.2026](#) · ●●●○○ 3/5

MAI-Code-1-Flash (MoE, 137B total / 5B aktiv) und MAI-Thinking-1 (1T total / 35B aktiv). In Microsofts eigenen Blind-Evals wurde MAI-Thinking-1 ggü. Claude Sonnet 4.6 bevorzugt – erstes glaubwürdiges Drittanbieter-Signal, dass ein Microsoft-Modell an der Frontier mitspielt (mit Vorsicht zu lesen).

Quellen: [Simon Willison](#) → · [microsoft.ai](#) →

5

LM Studio LM Link: lokale Mac-Modelle vom iPhone steuern

Tools & IDEs [LM Studio: LM Link](#) · 05.06.2026 · ●●●○○ 3/5

LM Link verbindet die LM-Studio-Desktop-App mit der iOS-App 'Locally AI': Die Rechenarbeit bleibt auf dem Mac, das iPhone ist nur mobiles Interface. Läuft im selben privaten Netz (Ende-zu-Ende-verschlüsselt, auf angepassten Tailscale-Mesh-Komponenten), unterstützt alle lokal installierten Modelle inkl. der Apple Intelligence Foundation Models. Aktuell kostenlose Preview. Quelle stammt aus GitHub-/Web-Trending dieser Woche.

Quellen: [LM Studio: LM Link](#) → · [Caschys Blog](#) →

6

Ollama-Bibliothek auf 4.500+ Modelle – Top-Picks für Consumer-Hardware

Open Weight / Lokal [promptquorum](#) · Juni 2026 · ●●○○○ 2/5

Die Ollama-Bibliothek umfasst rund 4.500+ Modelle. Aktuelle Empfehlungen: Qwen 3.6 27B (bestes Gesamtpaket, 24 GB Q4), Kimi K2.6 (Coding), gpt-oss:20b (klein/16 GB), Llama 4 Scout (Long-Context/multimodal), DeepSeek-R1 (Reasoning).

Quellen: [promptquorum](#) → · [Ollama Library](#) →

7

ainstype: lokale On-Device-Spracherkennung (WhisperKit) für macOS

[Tools & IDEs](#) GitHub: ainstype · KW23 · ●●○○○ 2/5

macOS-Menubar-App: Hotkey halten, sprechen, loslassen – Transkript landet in der aktiven App. Basiert auf WhisperKit (CoreML-Whisper) auf Apple Silicon, läuft komplett on-device, eigene Fachwörterbücher. Lokale Diktier-Alternative zu Cloud-STT in datenschutzkritischen Setups.

Quellen: [GitHub: ainstype](#) →

Überspringen kannst du in diesem Zeitraum

Themen, die durch die Presse gingen, aber keinen eigenen Eintrag bekommen — hier kurz erklärt, warum.

- **Noch nicht veröffentlicht:** MiniMax-M3-Gewichte und Tech-Report sind angekündigt, aber noch nicht auf Hugging Face/GitHub – bis dahin nur herstellergemessene Benchmarks.

Hinweis: Alle Infos auf eigene Gefahr. Dies ist ein privates Projekt, automatisch generiert aus Web-Recherche und dem Second Brain (Collana Gildentreffen).

Aufbau nach dem Tech-Radar-Prinzip (Ringe = Impact, Segmente = Kategorie), Design adaptiert von [private-apple-briefing](#) (MIT). Statischer Export, kein JavaScript. Auswahl per Recherche — keine Gewähr auf Vollständigkeit.